**UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA**

*La Universidad Católica de Loja*

Departamento de Ingenierías y Arquitectura

**Carrera de Computación**

**PRÁCTICAS PRE PROFESIONALES**

# ESTADO DEL ARTE

*Énfasis en Ingeniería de Datos*

**AUTOR:**

Jesús Alejandro Rivas Reinoso

**TUTOR:**

Ing. Francisco Oswaldo Vargas Naula

**PERÍODO ACADÉMICO:**

Abril 2026 – Agosto 2026

Loja – Ecuador

**2026**

# *Resumen/Abstract*

El volumen de datos generados en entornos digitales ha crecido de manera exponencial, impulsado por el auge de internet, los dispositivos IoT, las redes sociales y la inteligencia artificial. Ante este escenario, la ingeniería de datos emerge como disciplina fundamental para diseñar, construir y mantener sistemas que permitan extraer valor real de la información. El presente Estado del Arte examina las herramientas, arquitecturas y tendencias predominantes en la industria para la gestión de flujos de datos a gran escala, con énfasis en los modelos ETL y ELT, los pipelines de datos y su orquestación. A través del análisis de casos de estudio aplicados en entornos universitarios e industria financiera, se identifican tecnologías clave como Apache Spark, Databricks, dbt, Prefect/Airflow y Snowflake como pilares del ecosistema moderno de datos. Los resultados revelan que el paradigma ELT ha desplazado al ETL tradicional por su mayor eficiencia en entornos cloud, y que la observabilidad y la preparación de datos para modelos de IA son las prioridades emergentes para el período 2026–2028. Este análisis fundamenta el trabajo práctico desarrollado en la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD) de la Universidad Técnica Particular de Loja.

The volume of data generated in digital environments has grown exponentially, driven by the rise of the internet, IoT devices, social networks, and artificial intelligence. In this context, data engineering emerges as a fundamental discipline for designing, building, and maintaining systems that enable organizations to extract real value from information. This State of the Art document examines the predominant tools, architectures, and industry trends for managing large-scale data flows, with emphasis on ETL and ELT models, data pipelines, and their orchestration. Through the analysis of case studies applied in university environments and the financial industry, key technologies such as Apache Spark, Databricks, dbt, Prefect/Airflow, and Snowflake are identified as pillars of the modern data ecosystem. The findings reveal that the ELT paradigm has displaced traditional ETL due to its greater efficiency in cloud environments, and that data observability and AI-readiness are the emerging priorities for the 2026–2028 period. This analysis provides the theoretical foundation for the practical work carried out at the Directorate of Information Technologies and Digital Transformation (DGTITD) of the Universidad Técnica Particular de Loja.

# *Introducción:*

Todos sabemos hoy en día que los datos han tomado más relevancia que nunca, tanto en empresas, como en aplicaciones y espacios que día a día trabajan usando datos, es de está manera que la explotación de datos es algo que se da de manera más común de lo que se cree ya que debido a medida que la tecnología se desarrolla y el uso de dispositivos digitales se facilita en todo el mundo, el volumen de datos producidos aumenta considerablemente. Esto se debe al crecimiento de internet, las redes sociales, los dispositivos IoT, el comercio electrónico y la computación en la nube. Cada vez más personas y máquinas se conectan a internet, lo que implica que se genera una cantidad de datos cada vez mayor segundo a segundo.

Así mismo con el "Boom" de la IA vemos de mejor manera la importancia de los datos, hoy en día, los datos lo son todo. Los algoritmos de IA son herramientas potentes y capaces de procesar grandes volúmenes de información, aprender patrones y tomar decisiones autónomas, sin embargo, este desempeño está estrictamente relacionado a la información que se le entrega: si estos no existieran, la IA no tendría de dónde aprender o extraer conocimiento. Así mismo debemos tener en cuanto que se debe hacer respetar la "Gobernanza de datos" de cada empresa que emite estos datos, ya que no podemos pasar por alto las normas y dar cualquier dato a la IA. Debemos tener muy en claro que los datos que se entregan a la IA deben ser claras, ya que es mejor 1 archivo con datos limpios y claros que 100 archivos desarreglados y con información incompleta.

Es aquí donde surge uno de los mayores retos técnicos actuales: la escalabilidad y orquestación del flujo de datos. Las bases de datos tradicionales y las extracciones manuales ya no son suficientes para soportar el volumen, la velocidad y la variedad de información que ingresa constantemente. Si bien hoy en día existen arquitecturas y tecnologías diseñadas para procesar datos a gran escala, el verdadero desafío radica en construir *pipelines* (tuberías de datos) que sean eficientes, tolerantes a fallos y que mantengan la calidad de la información desde su origen hasta su consumo final.

En el contexto de la Universidad Técnica Particular de Loja (UTPL), la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD) opera los sistemas que sostienen la vida académica y administrativa. Garantizar que esta información fluya de manera correcta, segura y optimizada es vital para la toma de decisiones institucionales.

Por lo tanto, este documento de Estado del Arte busca explorar las soluciones actuales a este desafío, planteando las siguientes preguntas de investigación: ¿Cuáles son las herramientas predominantes en la industria para la extracción, transformación y orquestación de datos a gran

escala? y ¿Cómo están aplicando otras instituciones estas tecnologías para modernizar sus ecosistemas analíticos?

# *Marco Conceptual*

Primero para comenzar con los conceptos, es fundamental definir la disciplina central de este estudio, veamos: ¿Qué es al Ingeniería en Datos? Según Databricks, la ingeniería de datos se define textualmente como:

"*la práctica de diseñar, construir y mantener sistemas que recopilan, almacenan, transforman y entregan datos para su análisis, generación de informes, aprendizaje automático y toma de decisiones. Se trata de asegurarse de que los datos realmente lleguen a tiempo y en buen estado*" (Databricks)

Tomando esto en consideración, surge la necesidad de comprender qué recursos tecnológicos utilizan los ingenieros de datos para construir y mantener estos sistemas. El elemento fundamental que permite automatizar y estructurar el procesamiento de la información es el *Pipeline* (o canalización de datos).

Apoyándonos en la definición de Amazon Web Services (s.f), que textualmente nos indica:

*"Una canalización de datos consiste en una serie de pasos de procesamiento dirigidos a preparar los datos empresariales para llevar a cabo análisis [...] Sin embargo, los datos sin procesar carecen de utilidad; se deben trasladar, ordenar, filtrar, reformatear y analizar para adquirir inteligencia empresarial [...] Las canalizaciones de datos bien organizadas facilitan diversos proyectos de big data, como las visualizaciones de datos, los análisis exploratorios de datos y las tareas de machine learning."*

Una vez entendido el propósito que tienen los pipelines, es de importancia abordar los dos más conocidos modelos de la arquitectura de datos.

Históricamente la ingeniería de datos a operado bajo el paradigma conocido como modelo tradicional ETL (Extraer – Transformar - Cargar), la cual Amazon Web Services (s.f), nos define su procesamiento como:

"*El enfoque de ETL utiliza un conjunto de reglas empresariales para procesar datos de varios orígenes antes de la integración centralizada [...] El proceso de ETL consta de tres pasos: extracción de datos sin procesar, uso de un servidor de procesamiento secundario para transformar esos datos y carga en una base de datos de destino*"

Sin embargo, a medida que los avances lo han requerido, surgió el paradigma conocido modelo moderno ELT (Extraer – Cargar – Transforma), que aprovecha la potencia de la nube. Al respecto, Amazon Web Services (s.f.) indica que:

*"El enfoque de ELT carga los datos tal como están y los transforma en una etapa posterior [...] Toda la limpieza, la transformación y el enriquecimiento de los datos se producen dentro del almacenamiento de datos [...] El proceso de ELT es más rápido que el de ETL [y] se ha convertido en la norma en la actualidad"*

Este cambio de paradigma tuvo un gran impacto, ya que ahora es posible gestionar todo tipo de información, incluyendo datos no estructurados, utilizando la potencia de procesamiento y la paralelización de los almacenes de datos modernos para ofrecer transformaciones en tiempo real. Esto ha permitido que los equipos técnicos se enfoquen en el análisis de la información en lugar de invertir todo su esfuerzo en la transformación previa, aliviando la enorme carga operativa que supone el volumen diario de datos que ingresan a los sistemas en la nube.

# *Trabajos Relacionados*

Para poder reafirmar los conceptos antes expuestos y más en concreto de los Pipelines, tomaremos de ejemplo una implementación pensada para las universidades.

En lo que respecta al ámbito académico y más en concreto a las universidades, la implementación de los pipelines de datos para analizar la infraestructura de red se ha convertido en el núcleo operativo de los denominados “Smart Campuses”. En este caso de estudio veremos *“Un enfoque de aprendizaje automático para estimar el número de personas utilizando datos WiFi anónimos en una biblioteca universitaria.”*
Un caso destacado es la investigación de Hernando-Cánovas et al. (2025), quienes desarrollaron un sistema predictivo para estimar la ocupación física en una biblioteca universitaria utilizando datos anónimos de conexiones WiFi. Para lograr esto, los autores diseñaron un flujo que extrae registros continuos de los puntos de acceso inalámbricos (telemetría de red), procesando estas variables para alimentar modelos de machine learning. Al finalizar su estudio, los autores concluyen textualmente que "la estimación de ocupación basada en WiFi ofrece una solución robusta, rentable y que preserva la privacidad para implementaciones en el mundo real" (Hernando-Cánovas et al., 2025, p. 1).

Como segundo caso tenemos uno que se enfoca en la industria de los servicios financieros, donde se busca la implementación de *pipelines* de datos para procesar grandes cantidades de información con baja latencia, algo que se ha convertido en un requisito fundamental para la toma de decisiones operativas.

En este trabajo la tesis de Ahonen (2025), quien desarrolló una arquitectura para integrar datos desde sistemas heredados hacia plataformas modernas en la nube. Para lograr esto, el autor diseñó un flujo utilizando Apache Spark Structured Streaming que captura eventos continuos de cambios en bases de datos a través de Azure Event Hubs, procesando y fusionando estos registros para mantener un perfil de cliente unificado en tiempo real.

Al concluir su estudio, Ahonen(2025) pudo demostrar tiempos de respuesta sumamente bajos (entre 1.2 y 1.4 segundos), el autor concluye textualmente que "el streaming estructurado en Databricks es un enfoque viable y de alto rendimiento para pipelines de datos en tiempo real en entornos empresariales" (Ahonen, 2025, p. 58).

# *Herramienta y Tecnologías*

| HERRAMIENTA | FUNCIÓN PRINCIPAL | CARACTERÍSTICA DESTACADA |
|---|---|---|
| **Apache Spark** | Procesamiento distribuido (Batch/Streaming) | Motor clave para analítica masiva y flujos de baja latencia con Structured Streaming. |
| **Python / Scala** | Desarrollo de lógica y limpieza de datos | Lenguajes versátiles para el manejo de datasets complejos y modelos de machine learning. |
| **Databricks** | Plataforma de analítica unificada | Entorno en la nube que optimiza la ejecución de Spark para entornos empresariales. |
| **Azure Event Hubs** | Ingestión de datos en tiempo real | Servicio de transmisión de eventos de alta capacidad para capturar datos de sistemas heredados. |
| **dbt (Data Build Tool)** | Transformación en el almacén (ELT) | Permite transformar datos crudos en tablas analíticas usando únicamente SQL versionado. |
| **Prefect / Airflow** | Orquestación de flujos de trabajo | Coordinación automatizada de tareas, manejo de reintentos y monitoreo de dependencias. |
| **Snowflake** | Almacenamiento de datos (Cloud Warehouse) | Repositorio columnar escalable que permite separar el almacenamiento del cómputo. |
| **Power BI / Tableau** | Visualización y BI | Transformación de datos procesados en indicadores interactivos para la toma de decisiones. |

# *Tendencias Y Futuro*

El campo de la ingeniería de datos se encuentra en una fase de transformación acelerada. Para el periodo 2026-2028, se identifican tres tendencias críticas que redefinirán la forma en que las organizaciones gestionan su información:

**1. IA Agéntica y "AI-Ready Data":** La tendencia principal es el paso de simples tuberías de datos a "tuberías de contexto". La ingeniería de datos ya no solo busca mover tablas, sino preparar datos específicamente para ser consumidos por agentes de IA autónomos. Esto implica que los *pipelines* modernos ahora deben generar metadatos ricos y "embeddings" (vectores) de forma nativa, asegurando que la IA tenga un contexto confiable para actuar sin intervención humana constante.

**2. Observabilidad de Datos y "Governance as Code":** A medida que los flujos se vuelven más complejos, la prioridad ha pasado del simple rendimiento a la confianza total. La tendencia es integrar la observabilidad de datos como un estándar dentro del *stack* tecnológico. Esto permite monitorear de forma automática la "frescura", calidad y linaje de los datos, detectando anomalías o registros dañados mediante algoritmos predictivos antes de que estos afecten los tableros de control o los modelos de decisión.

**3. Edge Data Engineering:** Impulsado por el crecimiento de dispositivos IoT y redes WiFi inteligentes, el procesamiento se está desplazando hacia el "borde" (*Edge Computing*). Se estima que, para finales de 2026, una gran parte de los datos empresariales se procesará cerca de la fuente de origen. Esto permite filtrar y transformar información de alta frecuencia en tiempo real antes de enviarla a la nube, reduciendo costos de latencia y almacenamiento, lo cual es fundamental para aplicaciones de seguridad y monitoreo de infraestructura institucional.

# *Conclusiones:*

- **Superioridad del ELT**: El modelo Extraer-Cargar-Transformar es la opción más eficiente para la nube, ya que reduce tiempos de carga y permite procesar datos crudos (imágenes, logs, texto) con mayor flexibilidad que el método tradicional.

- **Vitalidad de la Orquestación**: Herramientas como Prefect o Airflow son el motor de confianza del sistema. Sin automatización de tareas y monitoreo de errores, es imposible escalar un flujo de datos sin riesgo de colapso.

- **Utilidad Práctica**: Los casos de estudio (como el de redes WiFi) confirman que la ingeniería de datos transforma registros técnicos simples en inteligencia operativa, permitiendo optimizar recursos y espacios físicos de forma real.

- **Preparación para la IA**: El futuro exige que los *pipelines* entreguen datos listos para IA. La prioridad ahora es la calidad y la observabilidad para alimentar modelos autónomos con información verídica en tiempo real.

# *Referencias:*


- Databricks. (s.f.). *¿Qué es la ingeniería de datos?*. Recuperado el 7 de mayo de 2026, de https://www.databricks.com/es/blog/what-is-data-engineering
- Amazon Web Services. (s.f.). *¿Qué es una canalización de datos?*. https://aws.amazon.com/es/what-is/data-pipeline/
- Amazon Web Services. (s.f.). *¿Cuál es la diferencia entre los procesos de ETL y ELT?*. Recuperado el 7 de mayo de 2026, de https://aws.amazon.com/es/compare/the-difference-between-etl-and-elt/
- Hernando-Cánovas, L., Martínez-Sala, A. S., Sánchez-Aarnoutse, J. C., & Alcaraz, J. J. (2025). A Machine Learning Approach for Estimating Person Counts Using Anonymous WiFi Data in a University Library. *Sensors*, *25*(22), 7065. https://doi.org/10.3390/s25227065
- Bismart. (2026). *Tendencias de datos 2026 que toda empresa debe conocer*. https://blog.bismart.com/tendencias-datos-2026-empresas
- CDO Magazine. (2026). *Why 2026 Will Redefine Data Engineering as an AI-Native Discipline*. https://www.cdomagazine.tech/opinion-analysis/why-2026-will-redefine-data-engineering-as-an-ai-native-discipline
- DataGrowth. (2026). *Las 25 Tendencias de Datos que Impulsarán las Empresas en 2026*. https://datagrowth.es/tendencias-datos-2026-empresas/ç