

INFORME: PROYECTO DE INGENIERÍA DE DATOS (RETO 1)

Nombre: Jesús Rivas Reinoso

1. Introducción y Diagnóstico del Dataset

En este proyecto armé un pipeline automatizado de Extracción, Transformación y Carga (ETL) con los registros administrativos del Ministerio de Educación (MINEDUC) para el periodo 2023-2024. El objetivo es limpiar y procesar toda esa data pesada para responder tres preguntas clave sobre la matrícula nacional y la educación en la provincia de Loja, guardando todo en una base de datos relacional antes de diseñar el dashboard.

Al revisar el archivo original en Python con la librería Pandas, me topé con que la data venía bien sucia:

- **Datos:** El archivo crudo es gigante, con miles de filas y más de 70 columnas porque venía todo desglosado por cada grado.
- **Títulos:** Los encabezados traían espacios en blanco invisibles al inicio y al final, lo que hace que Python se confunda al buscarlos.
- **Celdas vacías:** Había un montón de nulos (`NaN`) en las columnas de profesores y estudiantes porque muchas escuelas se olvidaron de reportar esos números.
- **Formato:** Los nombres de las columnas tenían tildes, mayúsculas y caracteres raros que rompen cualquier base de datos relacional si los dejas así.

2. Decisiones de Limpieza Justificadas (Las 4 Transformaciones)

Para arreglar todo ese relajo y dejar la data impecable, programé cuatro transformaciones fijas en mi código:

- **Transformación 1 (Estandarización):** Reduje las más de 70 columnas a solo 15 columnas esenciales para que la computadora no sufra con la memoria. Les cambié el nombre a todas usando minúsculas y guiones bajos (*snake_case*), mandando a volar las tildes y espacios para que la base de datos trabaje sin alergias.
- **Transformación 2 (Tratamiento de Nulos):** En las columnas de contar personas (estudiantes, profesores, hombres y mujeres), busqué cada celda vacía y le clavé un 0. Además, forcé a que toda la columna sea de números enteros (`int`) porque en una escuela no existen los "medios estudiantes".
- **Transformación 3 (Borrado de Duplicados):** Apliqué una purga estricta usando el código AMIE y el año lectivo como candado. Si una escuela aparecía dos veces en el mismo año por un error del sistema, borré los clones y dejé solo una fila para no inflar los KPI finales.
- **Transformación 4 (Prueba de la Calculadora):** Creé una auditoría matemática sumando las mujeres más los hombres y comparándolo con el total de estudiantes. Los registros con errores los dejé pasar para no perder el rastro de la

infraestructura de esa escuela, pero quedaron plenamente identificados en la terminal.

3. Estructura de los Scripts de Python Implementados

Para hacer las cosas bien y de forma ordenada en PyCharm, dividí el pipeline en tres scripts específicos:

- **Script 1 — Diagnóstico Inicial (1_exploracion.py):** Este primer archivo lo usé solo para abrir el CSV original por primera vez y "tomarle el pulso" a los datos. Aquí no alteré nada, sino que puse a Python a revisar las dimensiones de la tabla, contar cuántos nulos venían por columna y ver cómo estaba repartida la data en categorías clave como el sostenimiento y los niveles educativos. Esto me sirvió de mapa para saber exactamente qué tan sucia venía la información de origen y qué debía limpiar en el siguiente paso.
- **Script 2 — El Cerebro de la Limpieza (2_limpieza.py):** En este segundo módulo apliqué con código las cuatro transformaciones obligatorias. Primero, le pasé una tijera a los encabezados para borrar espacios fantasmas y renombré las columnas a un formato limpio sin tildes ni espacios. Luego, rellené con ceros los huecos vacíos en las columnas numéricas y las forcé a ser enteros para que no salieran decimales locos. Finalmente, le metí el filtro de duplicados por el código AMIE y el año escolar para borrar las escuelas repetidas, y corrí una auditoría matemática para chequear que la suma de hombres y mujeres cuadrara con el total de estudiantes reportado. Al cerrar, exporté todo en el archivo `MINEDUC_Limpio.csv`.
- **Script 3 — Carga y Validación SQL (3_carga_sqlite.py):** El último script se encarga de meter la data pulida dentro de la base de datos `amie_mineduc.db`. Primero, le puse un filtro preventivo para asegurarme de que solo pasen los datos del año lectivo 2023-2024 (con un seguro por si el formato del nombre variaba). Después, inyecté la tabla en SQLite desactivando el índice para no guardar basura. Por último, antes de abrir el Power BI, me puse el traje de auditor y corrí consultas en SQL puro directamente en la terminal de PyCharm (como sumas por provincias y el conteo de fiscales vs. particulares de Loja) para tener los números de control exactos y verificar que la base de datos responda rápido y sin errores.

4. Arquitectura y Almacenamiento Relacional (SQLite)

La base de datos relacional portátil se guardó bajo el nombre de `amie_mineduc.db`. Al configurar el parámetro `index=False` dentro del código, evité que Python guardara la columna automática de números correlativos de Pandas dentro de la base de datos. Gracias a esto, la tabla `instituciones` quedó normalizada, limpia de datos basura, ocupando menos espacio en el disco y súper rápida para cuando Power BI entre a leerla.

5. Diseño del Dashboard y Respuestas a las Interrogantes

En Power BI Desktop importé la base de datos SQLite y armé el reporte usando tres gráficos principales y una tarjeta de control:

Indicador Clave (KPI Central)

- **Gráfico:** Tarjeta (Card).
- **Qué hace:** Muestra la Matrícula Nacional Total sumando el campo de estudiantes. Funciona como el control global del dashboard reflejando un valor aproximado de 4 millones de estudiantes en todo el país.

Pregunta 1 (P1): Distribución de la matrícula en la provincia de Loja por cantones

- **Gráfico:** Barras Horizontales.
- **Configuración:** Cantón en el Eje Y, total de estudiantes en el Eje X, y un filtro en el gráfico para que `provincia == 'LOJA'`.
- **Análisis:** El gráfico muestra clarito cómo el cantón Loja (la cabecera) se lleva la barra más gigante y centraliza casi toda la matrícula de la provincia. Esto tiene todo el sentido del mundo porque ahí se concentra la mayor densidad poblacional y están los colegios más grandes, dejando muy por detrás a cantones como Catamayo o Calvas.

Pregunta 2 (P2): Proporción de instituciones fiscales vs. particulares por área en Loja

- **Gráfico:** Columnas Agrupadas (Verticales).
- **Configuración:** El área (Urbana/Rural) en el Eje X, el recuento de códigos AMIE en el Eje Y, y el sostenimiento metido en la Leyenda para que pinte las barras por colores. El filtro del gráfico está amarrado para que solo muestre `provincia == 'LOJA'` y en sostenimiento solo estén marcados **Fiscal** y **Particular**.
- **Análisis:** Aquí se nota una realidad clarísima: en el sector Rural de Loja, la educación Fiscal (pública) manda de forma casi absoluta, y las escuelas particulares son casi inexistentes. En cambio, en el sector Urbano, aunque el estado sigue liderando con las fiscales, los colegios particulares (privados) entran con muchísima más fuerza y se llevan un pedazo bien visible del pastel.

Pregunta 3 (P3): Evolución del número de instituciones activas entre 2015 y 2024

- **Gráfico:** Líneas.
- **Configuración:** Año lectivo en el Eje X y recuento de escuelas en el Eje Y.
- **Nota de Escalabilidad:** Como el pipeline actual se enfocó en limpiar el archivo vigente de este periodo (2023-2024), el gráfico muestra un punto de control específico en la pantalla. Lo bueno es que la estructura quedó idéntica y automatizada; el día en que le metamos los archivos CSV de los años pasados a la base de datos, la línea se va a dibujar sola por completo mostrando la evolución histórica en un segundo.