

De Manual a Escalable: Automatización RPA y Arquitectura Medallón para el Tablero del Macroentorno Ecuatoriano

Jesús Alejandro Rivas Reinoso

*Carrera de Computación,
Universidad Técnica Particular
de Loja (UTPL)*

Abstract—Obtener datos es solo el primer paso; el verdadero desafío está en transformarlos, estructurarlos y garantizar que el proceso se repita sin depender de que una persona recuerde cómo hacerlo. Este artículo documenta el desarrollo y cierre de un pipeline de datos institucional construido en la DGTITD de la Universidad Técnica Particular de Loja: el Pipeline del Macroentorno Ecuatoriano, que integra nueve fuentes públicas (BCE, INEC, Supercías, MINEDUC) bajo la arquitectura Medallón. En la capa Bronze, un componente de RPA automatiza la extracción de las fuentes y las deposita empaquetadas en formato JSON dentro de una base Oracle. En la capa Silver, un script maestro en Python consume ese repositorio mediante `oracledb`, aplanar los JSON anidados con `pandas` (`json_normalize`), corrige la codificación de caracteres y carga los datos por lotes en una base relacional con modelo estrella (dimensiones `dim_geografia` y `dim_tiempo` compartidas). En la capa Gold, siete vistas SQL calculan los indicadores que responden a tres preguntas estratégicas y alimentan un dashboard interactivo en Power BI vía ODBC. Todo el flujo se orquesta con Prefect. El pipeline procesó más de 1,9 millones de registros, y su hallazgo de mayor valor —el cruce entre bachilleres de tercer año y empresas activas por provincia— revela brechas regionales entre la oferta de talento joven y la capacidad de absorción del tejido empresarial.

I. INTRODUCCIÓN

Recopilar datos no es suficiente. El valor analítico de cualquier fuente depende de cuánto esfuerzo se invierte en limpiarla, estructurarla y hacerla coherente con otras fuentes. Majid et al. [3] estiman que la adquisición y preparación de datos consumen hasta el 80% del tiempo en proyectos analíticos reales, y Biswas et al. [6] confirman que estos pasos están presentes en prácticamente todos los flujos de trabajo, sin importar el dominio. A pesar de ello, en muchas organizaciones estos procesos siguen siendo manuales, no documentados y dependientes de personas específicas, lo que los vuelve frágiles ante cualquier cambio en las fuentes o en el equipo.

Ese fue exactamente el escenario que motivó este trabajo. La DGTITD de la UTPL mantenía un Tablero Macroentorno que integra indicadores económicos y laborales de nueve fuentes públicas ecuatorianas, pero su actualización era manual y su pipeline no estaba documentado ni era reproducible: cuando cambiaba un archivo fuente, el conocimiento de qué hacer vivía en personas, no en código. El objetivo del prácticum en el que se enmarca este artículo fue construir el pipeline que hace ese proceso sostenible y reproducible, desde los archivos crudos que entrega el equipo de RPA hasta un dashboard que responde a tres preguntas analíticas concretas. Ese objetivo se cumplió: el pipeline hoy está implementado, orquestado y operando sobre datos reales. El sistema sigue la arquitectura Medallón en sus tres capas: Bronze (datos crudos consolidados por RPA en Oracle), Silver (modelo relacional en estrella sobre SQLite) y Gold (vistas de negocio que consume Power BI).

Este artículo revisa la literatura que sustentó las decisiones de diseño del pipeline y muestra cómo cada una se materializó, en torno a tres preguntas: (1) ¿Qué arquitecturas organizan mejor el flujo desde datos crudos hasta indicadores listos para visualizar? (2) ¿Cómo estructurar el modelo relacional de la capa Silver para garantizar calidad y mantenibilidad? y (3) ¿Qué enfoques documentados son aplicables a pipelines institucionales con recursos tecnológicos acotados? El sistema construido, que procesa las nueve fuentes de extremo a extremo, sirve como caso de contraste concreto a lo largo de la revisión.

II. MARCO CONCEPTUAL

A. Pipelines de Datos: Un pipeline de datos es una serie de pasos de procesamiento automatizados que mueven, transforman y entregan información desde su origen hasta un destino apto para análisis. Según Majid et al. [3], el propósito central es transformar datos crudos en una forma estructurada que sirva de entrada a

tareas posteriores; estas actividades consumen hasta el 80% del tiempo de un proyecto de IA. Biswas et al. [6] encontraron que la adquisición, preparación y almacenamiento están presentes en prácticamente todos los flujos reales, confirmando que la normalización y limpieza concentran el mayor esfuerzo técnico, muy por encima de la simple extracción o la visualización final.

B. Arquitecturas ETL y ELT: Históricamente, la ingeniería de datos operó bajo el paradigma Extraer–Transformar–Cargar (ETL). Su dependencia de una capa de transformación separada introduce cuellos de botella al manejar datos de alta velocidad o no estructurados [4]. La aparición de almacenes en la nube habilitó el paradigma ELT (Extraer–Cargar–Transformar), donde los datos crudos se cargan directamente y las transformaciones se ejecutan después. Armbrust et al. [4] demuestran que la arquitectura Lakehouse permite tanto la retención flexible de datos crudos como transformaciones de alto rendimiento. En la práctica, muchos pipelines modernos orientados a entornos con infraestructura limitada operan con arquitecturas híbridas [3], usando enfoques ELT para la ingesta cruda y ETL para el modelado relacional ligero.

C. Orquestación de Datos: La orquestación coordina automáticamente múltiples tareas interdependientes dentro de un pipeline. Herramientas robustas como Apache Airflow implementan el paradigma *Workflows as Code* mediante grafos acíclicos dirigidos (DAGs) en Python [5]. Sin embargo, Mir et al. [5] documentan que la configuración, despliegue de metadatos y mantenimiento de estas plataformas presentan una curva de aprendizaje considerable y exigen alta infraestructura. Esto ha impulsado el uso de alternativas de orquestación más ligeras (como Prefect o Dagster), cuyo beneficio central no es únicamente programar horarios, sino aislar los procesos mediante decoradores en el código para eliminar los fallos silenciosos y reportar el estado de cada tarea individualmente.

III. TRABAJOS RELACIONADOS

Rana et al. [1] ofrecen una visión de conjunto del estado de la ingeniería de datos, subrayando que la disciplina ha madurado más en sus herramientas que en sus prácticas de documentación y reproducibilidad, una brecha que este proyecto buscó cerrar al formalizar en código un proceso que antes residía en la memoria de sus operadores. Majid et al. [3] categorizan las soluciones en cuatro grupos: pipelines ETL/ELT, herramientas de ingesta y

transformación, plataformas de orquestación y pipelines de aprendizaje automático; el sistema construido cubre los tres primeros y deja el cuarto como trabajo futuro. Heck [2] mapea las actividades de ingeniería de datos a lo largo del ciclo de vida de sistemas de IA, identificando la preparación y transformación como las más estudiadas, con escasez relativa en gobernanza y observabilidad.

Armbrust et al. [4] introducen la arquitectura Lakehouse, que combina la flexibilidad de los data lakes con el rendimiento de los almacenes tradicionales. Mir et al. [5] realizan un estudio empírico sobre los desafíos de implementar *Workflows as Code* en Airflow, analizando más de 9.000 publicaciones en Stack Overflow. Biswas et al. [6] confirman empíricamente la universalidad de los patrones de adquisición y preparación de datos. Ghosh et al. [12] sitúan a la RPA como habilitador de la recolección automatizada de datos, y Bala Krishna y Kumar [13] fundamentan el modelado en estrella como técnica de diseño para almacenes analíticos.

IV. METODOLOGÍA Y CASO DE ESTUDIO INSTITUCIONAL

El proyecto se estructuró adaptando los principios de la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) a la ingeniería de datos, aplicados directamente al caso de estudio de la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD) de la UTPL.

La fase de *Comprensión del Negocio* consistió en levantar las tres preguntas estratégicas que debía responder el tablero y delimitar las nueve fuentes públicas (BCE, INEC, Supercías y MINEDUC). La *Preparación de los Datos* se materializó en las capas Bronze y Silver de la arquitectura Medallón: la ingesta automatizada depositó los datos crudos en Oracle, y un proceso en Python los modeló en estrella sobre SQLite. El *Modelado* se concretó en la construcción de las vistas analíticas de la capa Gold. Finalmente, el *Despliegue* se cumplió al publicar el tablero interactivo en Power BI. Todo el ciclo fue gobernado bajo la orquestación de Prefect para garantizar su reproducibilidad.

V. HERRAMIENTAS Y TECNOLOGÍAS

La Sección V describe la arquitectura implementada capa por capa. La Tabla I resume las herramientas efectivamente empleadas, alineadas con la taxonomía de Majid et al. [3].

TABLE I. TABLA I

TABLE II. STACK TECNOLÓGICO IMPLEMENTADO EN EL PIPELINE

Herramienta	Función en el pipeline	Rol efectivo en la implementación
RPA (Capa Bronze)	Extracción automatizada	Descarga las 9 fuentes públicas y las deposita como JSON en TAB_CONSOLIDADO (Oracle), eliminando la descarga manual [12]
Oracle oracledb	+ Landing zone y conectividad	Oracle almacena el JSON crudo sin esquema previo; oracledb lo extrae por lotes desde Python [4]
Python pandas	/ Lógica y limpieza	json_normalize aplan los JSON anidados; corrección de codificación y normalización [3]
SQLite	Almacén Silver / Gold	Base relacional local liviana, coherente con entornos de infraestructura acotada [3]
SQL (Modelo estrella)	Modelo relacional	dim_geografia y dim_tiempo como dimensiones compartidas; hechos con claves foráneas [13]
Prefect	Orquestación	Decoradores @task y @flow; trazabilidad por tarea sin la curva de Airflow [5]
SQL (Vistas Gold)	Indicadores de negocio	Siete vistas analíticas ejecutadas desde Python que responden las 3 preguntas del dashboard
Power (ODBC)	BI Visualización	Consume las vistas Gold y las convierte en indicadores interactivos de tres páginas [1]

VI. RESULTADOS

La ejecución del pipeline arrojó resultados tangibles que confirman la viabilidad de la arquitectura propuesta. El proceso automatizado transformó y cargó exitosamente más de 1,9 millones de registros provenientes de las nueve fuentes públicas —destacando más de 1,6 millones de filas del ranking empresarial de Supercías y 212.000 del directorio de compañías— sin intervención manual.

Como producto de esta transformación, la capa Silver quedó consolidada en 7 tablas relacionales. Sobre ellas, la capa Gold materializó 6 vistas analíticas eficientes que precalcular los indicadores de negocio. Estas vistas alimentan un tablero interactivo en Power BI (ver Figura 1). El hallazgo de mayor valor estratégico expuesto en el tablero es el cruce entre bachilleres de tercer año y empresas activas por provincia, revelando brechas regionales entre

la oferta de talento joven y la capacidad de absorción del tejido empresarial local.



Figura 1.




Figura 2.

VII. RECOMENDACIONES Y TRABAJO FUTURO

IA predictiva sobre la capa Gold: la capa Gold es, por construcción, un conjunto de series históricas limpias, tipadas y consistentes, exactamente el insumo que Majid et al. [3] identifican como la barrera habitual para los pipelines de aprendizaje automático y que aquí ya está resuelta. La extensión natural es entrenar modelos predictivos sobre estas vistas: proyectar el ratio de `gold_bachilleres_vs_empresas` para anticipar en qué provincias la escasez de tejido empresarial no absorberá a los futuros graduados, y usar `gold_pib_tendencia` y `gold_empleo_tendencia` para modelos de series temporales. Esto alinearía el pipeline con la tendencia de datos listos para IA que documenta Heck [2].

Automatización proactiva mediante alertas: el dashboard actual es pasivo, informa a quien lo consulta. Dado que el flujo ya está orquestado con Prefect, incorporar una tarea de vigilancia posterior a las vistas Gold es de bajo costo: evaluaría umbrales críticos —una caída del PIB, un repunte del riesgo país, un descenso del empleo adecuado— y enviaría alertas automáticas por correo a los directivos. Este enfoque materializa lo que Ehrlinger y Rusz [10]

describen como observabilidad continua dentro del stack del pipeline, extendiendo la vigilancia desde la calidad técnica del dato hacia el valor de negocio del indicador.

Escalabilidad en la nube: SQLite fue la elección correcta para la construcción (cero costo, cero administración, suficiente para el volumen actual), pero su límite es la concurrencia y el acceso distribuido. Migrar la capa Silver/Gold a un servicio gestionado (AWS RDS, Azure SQL Database o Google BigQuery) democratizaría el acceso al lago de datos para que Planificación, Vinculación y las facultades consulten los mismos indicadores en tiempo real. La arquitectura Medallón facilita la transición: al estar la lógica desacoplada del destino, migrar implica sustituir la función de carga, no reescribir el pipeline, acercando la solución al modelo Lakehouse de Armbrust et al. [4] y el borde documentado por Hamid et al. [11].

VIII. CONCLUSIONES

El objetivo principal del proyecto se cumplió con éxito: el reto de automatizar la ingesta y hacer reproducible el pipeline del macroentorno ecuatoriano quedó plenamente logrado. El proceso manual y no documentado del punto de partida se transformó en un flujo automatizado, orquestado con Prefect y estructurado en capas, capaz de procesar más de 1,9 millones de registros sin intervención humana y de regenerarse de forma íntegra ante cualquier actualización.

A partir de este desarrollo, se destacan las siguientes conclusiones:

- **La transformación como núcleo del esfuerzo:** La literatura anticipaba que la preparación y limpieza de datos es la etapa más costosa y crítica de un proyecto analítico [3], [6], y el desarrollo lo confirmó. Sin embargo, delegar la ingesta a herramientas de RPA [12] eliminó la fragilidad de las descargas manuales y creó una división limpia y eficiente entre la recolección y el procesamiento.
- **Arquitectura funcional y mantenible:** La separación en las capas Bronze, Silver y Gold [3], [4], sumada a un modelo estrella con dimensiones compartidas [13], demostró ser una decisión estratégica antes que estética. Permitió que los equipos trabajaran independientemente sin tener que reprocesar las ingestas iniciales. Por su parte, la orquestación ligera con Prefect [5] brindó la trazabilidad necesaria para evitar fallos silenciosos sin requerir infraestructura costosa.

- **Alto impacto sin necesidad de algoritmos complejos:** La solidez del pipeline es el verdadero diferenciador [7], [9]. Se comprobó que cruces de alto valor estratégico —como el contraste entre los bachilleres graduados y el tejido empresarial para revelar brechas regionales de talento— se pueden lograr de forma efectiva mediante bases limpias y modelos bien planteados, sin recurrir a técnicas de aprendizaje automático.
- **La reproducibilidad como punto de partida:** Documentar y formalizar todo el pipeline en código transformó un proceso frágil y dependiente de la memoria humana en un activo institucional sostenible. Este nivel de automatización no es la meta final, sino el cimiento analítico: la misma capa Gold que hoy alimenta el tablero interactivo será la base exacta que mañana entrenará modelos predictivos y disparará alertas automáticas.

IX. REFERENCIAS

- [1] D. Rana, A. Bhatt, R. B. Dubey y S. K. Bhatt, “Data Engineering: An Overview from a Future Perspective,” en Proc. 2023 IEEE Int. Conf. on Contemporary Computing and Communications (InC4), IEEE, 2023. DOI: 10.1109/InC4.2023.10398128
- [2] P. Heck, “What About the Data? A Mapping Study on Data Engineering for AI Systems,” en Proc. CAIN 2024, ACM, Lisboa, abr. 2024. DOI: 10.1145/3644815.3644954
- [3] A. Majid, S. Laue, K. Böhm y N. Piatkowski, “A Survey of Pipeline Tools for Data Engineering,” arXiv preprint arXiv:2406.08335, 2024.
- [4] M. Armbrust et al., “Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics,” en Proc. 11th CIDR 2021, 2021.
- [5] H. Mir, D. Rajbahadur y Y. Tian, “An Empirical Study of Developers’ Challenges in Implementing Workflows as Code: Apache Airflow,” J. Systems and Software, vol. 217, 2024. DOI: 10.1016/j.jss.2024.112029
- [6] S. Biswas, M. Wardat y H. Rajan, “The Art and Practice of Data Science Pipelines,” en Proc. ICSE 2022, pp. 2091–2103. DOI: 10.1145/3510003.3510057
- [7] L. Hernando-Cánovas et al., “A Machine Learning Approach for Estimating Person Counts Using Anonymous WiFi Data in a University Library,” Sensors, vol. 25, n.º 22, p. 7065, 2025. DOI: 10.3390/s25227065
- [8] A. Alzahrani, B. Alharbi y K. Al-Tawil, “Apache Spark in Riot Games: A Case Study on Data Processing,” IJACSA, vol. 14, n.º 7, 2023. DOI: 10.14569/IJACSA.2023.0140704
- [9] J. Ahonen, “Real-Time Customer Data Platform using Apache Spark Structured Streaming and Databricks,” Tesis de Máster, Tampere University, 2025.
- [10] L. Ehrlinger y W. Ruzs, “A Survey of Data Quality Measurement and Monitoring Tools,” Frontiers in Big Data, vol. 5, 2022. DOI: 10.3389/fdata.2022.850611

- [11] A. Hamid et al., "Enhancing IoT Efficiency by Minimizing Latency with Edge Computing," SN Computer Science, Springer, 2025. DOI: 10.1007/s42979-025-04192-x
- [12] S. Ghosh, R. Shetty et al., "Robotics Process Automation Technologies for Data Collection and Analysis," en Proc. 2024 IEEE Int. Conf., IEEE, 2024. DOI: 10.1109/ICKECS.2024.10725006
- [13] R. Bala Krishna y S. Kumar, "Dimensional Modeling Using Star Schema for Data Warehouse Creation," Oriental J. of Computer Science and Technology, vol. 10, n.º 4, 2017.