

Estado del Arte

Jesús Alejandro Rivas Reinoso

*Carrera de Computación, Universidad
Técnica Particular de Loja (UTPL)*

Abstract—El volumen de datos generado en entornos digitales ha crecido exponencialmente impulsado por el auge de internet, los dispositivos IoT, las redes sociales y la inteligencia artificial. La ingeniería de datos emerge como disciplina fundamental para diseñar, construir y mantener sistemas que extraigan valor de la información. Este artículo revisa herramientas, arquitecturas y tendencias predominantes para la gestión de datos a gran escala, con énfasis en los modelos ETL y ELT, el procesamiento distribuido y la orquestación de flujos de trabajo. A través del análisis de casos de estudio en entornos universitarios Smart Campus e industria financiera, se identifican Apache Spark, Databricks, dbt, Apache Airflow y Snowflake como pilares del ecosistema moderno de datos. Los resultados indican que el paradigma ELT ha desplazado progresivamente al ETL tradicional, y que la observabilidad de datos y la preparación para IA son las prioridades emergentes para 2026–2028

I. Introducción

El volumen de datos producidos a nivel global ha aumentado a una tasa sin precedentes durante la última década, impulsado por la expansión de internet, plataformas de redes sociales, dispositivos IoT y la adopción masiva de inteligencia artificial. Como señalan Rana et al. [1], la ingeniería de datos se ha convertido en materia esencial para manejar, procesar y analizar grandes volúmenes de información procedentes de fuentes y formatos diversos, abarcando el diseño, construcción y mantenimiento de pipelines, sistemas de almacenamiento y marcos de transformación.

El auge del aprendizaje automático ha amplificado esta importancia estratégica. Heck [2] argumenta que los sistemas de IA no pueden existir sin datos correctamente procesados; cada pipeline de entrenamiento o inferencia depende de información estructurada, limpia y trazable, lo que ha desplazado el enfoque hacia garantizar calidad, linaje y preparación para consumo algorítmico.

En el contexto de la Universidad Técnica Particular de Loja (UTPL), la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD) opera los sistemas que sostienen la vida académica y administrativa institucional. Este artículo aborda: (1) ¿Cuáles son las herramientas predominantes para la extracción, transformación y orquestación de datos a gran escala? y (2) ¿Cómo están aplicando las instituciones estas tecnologías para modernizar sus ecosistemas analíticos?

II. MARCO CONCEPTUAL

A. Pipelines de Datos

Un pipeline de datos es una serie de pasos de procesamiento automatizados diseñados para mover, transformar y entregar información desde su origen hasta un destino adecuado para análisis. Según Majid et al. [3], el

propósito central es transformar datos crudos en una forma estructurada que sirva como entrada a tareas posteriores; estas actividades consumen hasta el 80% del tiempo de trabajo en un proyecto de IA. Biswas et al. [7] encontraron que la adquisición, preparación y almacenamiento de datos están presentes en prácticamente todos los flujos de trabajo reales, independientemente del dominio de aplicación.

B. Arquitecturas ETL y ELT

Históricamente, la ingeniería de datos operó bajo el paradigma Extraer–Transformar–Cargar (ETL): los datos se extraen, se transforman en un servidor intermedio y se cargan en la base destino. Sin embargo, su dependencia de una capa de transformación separada introduce cuellos de botella al manejar datos de alta velocidad o no estructurados [4].

La aparición de almacenes de datos en la nube habilitó el paradigma ELT (Extraer–Cargar–Transformar), donde los datos crudos se cargan directamente y las transformaciones se realizan después, aprovechando la potencia nativa del almacén. Armbrust et al. [4] demuestran que la arquitectura Lakehouse permite tanto la retención flexible de datos crudos como transformaciones de alto rendimiento sin servidor ETL dedicado. Herramientas como dbt expresan esta lógica en SQL con control de versiones, incorporando buenas prácticas de ingeniería de software a la capa de transformación [3].

C. Orquestación de Datos

La orquestación coordina automáticamente múltiples tareas interdependientes dentro de un pipeline. Apache Airflow implementa el paradigma Workflows as Code mediante grafos acíclicos dirigidos (DAGs) en Python. Mir et al. [5] reportan que organizaciones como Google, Adobe y PayPal dependen de Airflow para gestionar flujos complejos, aunque documentan desafíos en configuración y entornos de ejecución distribuida. Herramientas como Prefect ofrecen abstracciones más livianas para equipos que requieren una incorporación más rápida.

III. TRABAJOS RELACIONADOS

Rana et al. [1] ofrecen una visión orientada al futuro de la disciplina, subrayando la creciente relevancia del campo conforme los volúmenes de datos continúan escalando. Majid et al. [3] categorizan las soluciones disponibles en cuatro grupos: pipelines ETL/ELT, herramientas de ingesta y transformación, plataformas de orquestación y pipelines de aprendizaje automático. Heck [2] mapea las actividades de ingeniería de datos a lo largo del ciclo de vida completo de la IA, identificando la preparación y transformación como las actividades más estudiadas, con escasez relativa en gobernanza y observabilidad.

Armbrust et al. [4] introducen la arquitectura Lakehouse, que combina la flexibilidad de los data lakes con el rendimiento de los almacenes tradicionales. Mir et al. [5] realizan un estudio empírico sobre los desafíos al implementar Workflows as Code en Airflow, analizando más de 9.000 publicaciones en Stack Overflow. Biswas et al. [7] presentan un estudio empírico a gran escala que confirma la universalidad de los patrones de adquisición y preparación de datos en pipelines reales.

IV. CASOS DE ESTUDIO Y APLICACIONES

A. Entornos de Smart Campus Universitario

Hernando-Cánovas et al. [8] desarrollaron un sistema predictivo para estimar la ocupación física en una biblioteca universitaria usando datos anónimos de conexiones WiFi. El pipeline extrae continuamente registros de telemetría de puntos de acceso inalámbricos, procesa estas variables y alimenta modelos de aprendizaje automático para producir estimaciones de ocupación sin requerir cámaras ni datos de identificación personal. Los autores concluyen que esta solución es robusta, rentable y preserva la privacidad [8], ilustrando cómo un pipeline bien estructurado transforma telemetría de bajo nivel en inteligencia operativa de alto valor.

B. Industria Financiera

Ahonen [10] desarrolló una arquitectura para integrar datos desde sistemas bancarios heredados hacia plataformas modernas en la nube, utilizando Apache Spark Structured Streaming con Azure Event Hubs para capturar eventos continuos de cambio y mantener un perfil de cliente unificado. La latencia de extremo a extremo reportada de entre 1,2 y 1,4 segundos demuestra la viabilidad de Structured Streaming para pipelines empresariales en tiempo real; Ahonen concluye que Databricks es un enfoque viable y de alto rendimiento para estos escenarios [10].

V. HERRAMIENTAS Y TECNOLOGÍAS

La Tabla I resume las principales herramientas identificadas en la literatura revisada, alineadas con la taxonomía de Majid et al. [3].

TABLE I. TABLA I

TABLE II. PRINCIPALES HERRAMIENTAS DE INGENIERÍA DE DATOS			
Herramienta	Función principal		Característica destacada
Apache Spark	Procesamiento distribuido		Motor en memoria para analítica masiva y streaming de baja latencia [9]
Python / Scala	Lógica y limpieza de datos		Lenguajes versátiles para datasets complejos e integración con ML [3]
Databricks	Plataforma unificada	analítica	Entorno cloud que optimiza Spark para producción empresarial [9]
Azure Event Hubs	Ingesta en tiempo real	Transmisión de eventos de alta capacidad desde sistemas heredados [10]	
dbt	Transformación ELT		Transforma datos con SQL versionado dentro del almacén [7]
Apache Airflow / Prefect	Orquestación de flujos		Coordinación automatizada, reintentos y monitoreo de dependencias [5]
Snowflake	Almacén cloud		Repositorio columnar que desacopla almacenamiento y cómputo [4]
Power BI / Tableau	Visualización e BI		Convierte datos procesados en indicadores interactivos [1]

VI. TENDENCIAS Y FUTURO

Datos listos para IA y pipelines ágenticos: El cambio más significativo es la transición desde pipelines que mueven tablas hacia pipelines que preparan entradas contextuales para

agentes de IA autónomos. Heck [2] muestra que los pasos de preprocesamiento e ingeniería de características se han convertido en la restricción de diseño primaria, requiriendo que los pipelines generen metadatos enriquecidos y representaciones vectoriales de forma nativa.

Observabilidad de datos y gobernanza como código:

Ehrlinger y Rusz [11] identifican un desplazamiento hacia la detección automática de anomalías y el seguimiento de linaje que opera continuamente dentro del stack del pipeline. Este enfoque permite detectar deriva de esquema o registros corruptos antes de que afecten paneles de control o modelos de aprendizaje automático.

Edge Data Engineering: Hamid et al. [14] documentan cómo el procesamiento en el borde reduce la latencia al habilitar transformaciones cerca de la fuente. Para la ingeniería de datos, implica diseñar pipelines sobre topologías distribuidas que filtran y agregan datos de sensores de alta frecuencia en el borde antes de transmitir registros consolidados a la nube.

VII. DISCUSIÓN

La literatura revisada apunta consistentemente al paradigma ELT como modelo dominante para la ingeniería de datos basada en la nube. El cambio documentado por Armbrust et al. [4] desde los servidores ETL hacia las plataformas Lakehouse refleja una transformación más amplia: en lugar de transformar datos para ajustarlos a un esquema predefinido, el enfoque preferido es preservar los datos crudos y aplicar lógica de transformación bajo demanda.

Los casos de estudio revelan un patrón recurrente: el desafío central no es la recolección de datos sino su integración y confiabilidad. Hernando-Cánovas et al. [8] construyeron su sistema sobre una base de telemetría continua; los modelos de ML fueron secundarios al pipeline que entregaba datos limpios. Similarmente, Ahonen [10] logró su latencia sub-segundo mediante arquitectura cuidadosa, no mediante novedad algorítmica. Una limitación del presente estudio es la escasez de casos publicados en universidades latinoamericanas.

VIII. CONCLUSIONES

Superioridad del ELT en la nube: El modelo ELT se ha consolidado como paradigma dominante gracias a su capacidad de preservar datos originales, soportar retransformaciones flexibles y aprovechar recursos computacionales nativos del almacén.

La orquestación como requisito de producción: Apache Airflow y Prefect no son mejoras opcionales sino requisitos estructurales para operar pipelines confiables a escala.

Valor aplicado demostrado: Los casos en Smart Campus e industria financiera confirman que el factor habilitador clave es una infraestructura de pipeline confiable, no la sofisticación algorítmica.

Preparación para IA como siguiente frontera: Los pipelines del futuro deben entregar no solo datos limpios, sino también metadatos y representaciones vectoriales para agentes de IA autónomos.

REFERENCIAS

- [1] [1] D. Rana, A. Bhatt, R. B. Dubey y S. K. Bhatt, "Data Engineering: An Overview from a Future Perspective," en *Proc. 2023 IEEE Int.*

Conf. on Contemporary Computing and Communications (InC4), IEEE, 2023. DOI: 10.1109/InC4.2023.10398128

- [2] [2] P. Heck, "What About the Data? A Mapping Study on Data Engineering for AI Systems," en *Proc. CAIN 2024*, ACM, Lisboa, abr. 2024. DOI: 10.1145/3644815.3644954
- [3] [3] A. Majid, S. Laue, K. Böhm y N. Piatkowski, "A Survey of Pipeline Tools for Data Engineering," *arXiv preprint arXiv:2406.08335*, 2024.
- [4] [4] M. Armbrust et al., "Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics," en *Proc. 11th CIDR 2021*, 2021.
- [5] [5] H. Mir, D. Rajbahadur y Y. Tian, "An Empirical Study of Developers' Challenges in Implementing Workflows as Code: Apache Airflow," *J. Systems and Software*, vol. 217, 2024. DOI: 10.1016/j.jss.2024.112029
- [6] [7] S. Biswas, M. Wardat y H. Rajan, "The Art and Practice of Data Science Pipelines," en *Proc. ICSE 2022*, pp. 2091–2103. DOI: 10.1145/3510003.3510057
- [7] [8] L. Hernando-Cánovas et al., "A Machine Learning Approach for Estimating Person Counts Using Anonymous WiFi Data in a University Library," *Sensors*, vol. 25, n.º 22, p. 7065, 2025. DOI: 10.3390/s25227065
- [8] [9] A. Alzahrani, B. Alharbi y K. Al-Tawil, "Apache Spark in Riot Games: A Case Study on Data Processing," *IJACSA*, vol. 14, n.º 7, 2023. DOI: 10.14569/IJACSA.2023.0140704
- [9] [10] J. Ahonen, "Real-Time Customer Data Platform using Apache Spark Structured Streaming and Databricks," *Tesis de Máster, Tampere University*, 2025.
- [10] [11] L. Ehrlinger y W. Ruzs, "A Survey of Data Quality Measurement and Monitoring Tools," *Frontiers in Big Data*, vol. 5, 2022. DOI: 10.3389/fdata.2022.850611
- [11] [14] A. Hamid et al., "Enhancing IoT Efficiency by Minimizing Latency with Edge Computing," *SN Computer Science*, Springer, 2025. DOI: 10.1007/s42979-025-04192-x

